



江蹇



(+86) 182 1144 5116 | 202316187@stu.neu.edu.cn | 常住地: 广东惠州、深圳

教育经历

北京大学深圳研究生院 985 211 双一流

2027.09 - 2030.06

计算机科学与技术硕士

• 拟录取

东北大学 985 211 双一流

2023.09 - 2027.06

计算机科学与技术本科

• GPA: 4.19/5.00 (综合排名 5/196, 专业前 2.56%)

• CET-4: 579, CET-6: 528

• 部分课程: 高等数学 (一)(二) 99, 概率论 100, 最优化 97, 线性代数 92

论文发表

• 累计发表论文 4 篇, Google Scholar 引用 80 次; 以第一作者或共同第一作者发表 CCF-A 类会议论文 1 篇、CCF-B 类会议论文 1 篇; 以非主要作者发表 CCF-A 类会议论文 2 篇 (* 代表共同贡献)。

1. (共同一作, CCF-A, ACL 2026 Main) Zirui Song*, Qian Jiang*, et al. Audio Jailbreak: An Open Comprehensive Benchmark for Jailbreaking Large Audio-Language Models.

2. (第一作者, CCF-B, ICME 2026 Oral) Qian Jiang, Zhecheng Shi, et al. OmniFood-Bench: Evaluating VLMs for Nutrient Reasoning and Personalized Health Advice.

3. (非主要作者, CCF-A, AAAI 2026) Zirui Song*, Guanghan Ouyang*, ... Qian Jiang ..., et al. ManipLVM-R1: Reinforcement Learning for Reasoning in Embodied Manipulation with Large Vision-Language Models.

4. (非主要作者, CCF-A, ACL 2026 Findings) Fan Ji*, Juncheng Yang*, ... Qian Jiang ..., et al. FineState-Bench: Benchmarking State-Conditioned Grounding for Fine-grained GUI State Setting.

研究经历

MBZUAI (世界首所人工智能大学), 陈秀颖老师指导

• 开展 Trustworthy-AI 相关研究, 探索多模态大模型越狱攻击和可信 AI 文本生成检测。

东北大学语言与智能系统实验室, 方淼老师指导

• 开展 VLM 模型和 agents 相关研究, 目前作为第一学生负责人协助实验室招新与运营。

专业技能

Audio Jailbreak: An Open Comprehensive Benchmark for Jailbreaking Large Audio-Language Models 共一, CCF-A, ACL2026 main

构建针对大型音频语言模型的开源越狱基准 AJailBench, 填补音频模态大模型安全评测的研究空白, 从数万份数据中精选 1,495 个高质量对抗样本覆盖 10 大违规类别, 搭建 7 大主流语音模型统一评估流水线, 证实所有模型均无全维度防御鲁棒性。提出 APT 工具箱集成时域、频域、混合共 10 种扰动策略, 严格保障语义一致性; 引入贝叶斯优化通过余弦相似度构造目标函数逼近越狱参数分布, 攻击成功率提升约 10%。代码被收录到 MBZUAI 官方 team, 近一个月在 Hugging Face 上有 784 次下载量, 被由 ModelScope、Hugging Face、OpenCompass CompassHub 和 SmartFlowAI 等联合主办的 “AI Bench Talk” 邀请分享, 此外还被 MSN 等媒体报道, 为音频大模型安全防御研究提供测试基准。目前以共同第一作者被 ACL 2026 Main 接收。

OmniFood-Bench: Evaluating VLMs for Nutrient Reasoning and Personalized Health Advice 一作, CCF-B, ICME2026 Oral

针对现有食物基准仅关注粗粒度分类、缺失安全推理评估的问题, 构建三级渐进式 VLM 评估体系 (基础感知 → 定量推理 → 安全关键建议), 基于 MM-Food-100K 构建 1,208 个覆盖居家、餐厅、包装、生鲜四类场景的高质量样本。对 GPT-5.1、Gemini-3-flash 等 6 个 SOTA VLM 评测揭示 “语义-物理鸿沟”: 菜品识别接近人类水平, 但质量估计灾难性失败, 在糖尿病、肾病等高风险场景频繁产生安全幻觉, 最高安全建议准确率仅 46%, 为医疗级膳食大模型的可信部署提供严苛评测依据。目前以第一作者被 ICME 2026 Oral 接收。

AI Text Detectors as a House of Cards: From Vulnerability Induced by Decoding Strategies to Robustness Through Restoration

发现现有 Logit-based AI 文本检测器在面对不同解码策略时极其脆弱——Temperature 或 Repetition Penalty 的微小变化即可使检测 AUC 骤降至约 50%, 核心原因是解码策略改变模型 token 概率分布, 导致人机文本特征重叠无法区分。深入分析主流检测方法的数学共性, 给出统一的理论解释; 提出 Restore 变换, 搭建自适应分布校正器, 利用 Distinct-2、Trigram Repeat Ratio、Character Entropy 等特征学习映射函数, 将偏移分布拉回可检测空间, 在多模型、多数据集上显著恢复检测器鲁棒性, 突破解码策略带来的检测失效难题。

竞赛及其他成果

• 2026 年美国大学生数学建模竞赛 Finalist (特等奖提名奖, 前 0.1%-2%)

• 全球人工智能算法精英大赛全国总决赛三等奖; 提出 SLTP 旅行规划框架, 以双专家 LoRA 与师生蒸馏实现轻量模型高精度符号转换; 设计启发式树搜索兼顾约束合规与方案多样性。

• 知识博客: <https://www.zhihu.com/people/bu-neng-yao-gong>

• 学术社区学生负责人: <https://neuqnlp.github.io/team>